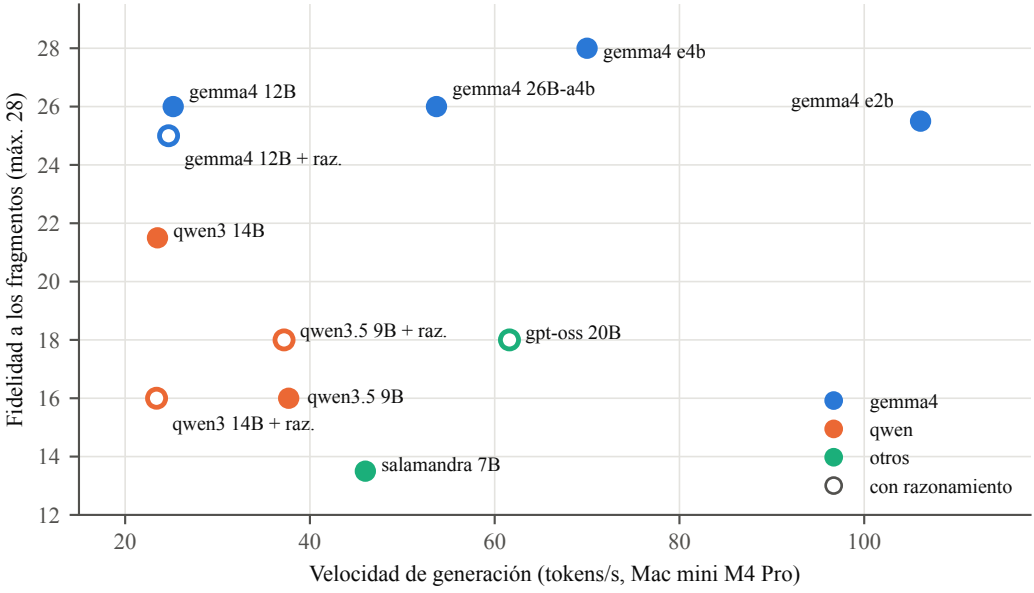
gemma4 e4b
gemma4 12B
gemma4 26B-a4b
gemma4 e2b
gemma4 12B + raz.
qwen3 14B
qwen3.5 9B + raz.
gpt-oss 20B
qwen3.5 9B
qwen3 14B + raz.
salamandra 7B
gemma4
qwen
otros
con razonamiento
Fidelidad a los fragmentos (máx. 28)
Velocidad de generación (tokens/s, Mac mini M4 Pro)
28
26
24
22
20
18
16
14
12
20
40
60
80
100