FIDELIDAD A LAS FUENTES DE MODELOS LOCALES EN RAG CON CITAS: ONCE CONFIGURACIONES EN UN ORDENADOR DE 24 GB

PREPRINT

Joaquín Herrero Pintado
Creative Codeworks
https://creativecodeworks.com

14 de octubre de 2026

RESUMEN

Comparo once configuraciones de modelos de lenguaje ejecutados en local (Ollama 0.40.4 en un Mac mini M4 Pro con 24 GB) en una tarea de generación aumentada por recuperación (RAG) con citas, en español, sobre [nombre de la wiki], una wiki de [tema] con [N] páginas. Para cada una de 14 preguntas, todos los modelos reciben los mismos ocho fragmentos y la instrucción de responder solo con ellos, citar y declarar lo que falta. Tres preguntas tratan de autores que no aparecen en el corpus. Dos evaluadores ciegos puntúan las 154 respuestas en fidelidad, citas, cobertura y contención, con un acuerdo exacto del 92–95 %. Las cinco primeras posiciones son de la familia gemma4. gemma4 e4b, con 6,6 GB como máximo y 70 tokens/s, es la única configuración con fidelidad perfecta y empata con gemma4 12B (109,5 y 108,5 sobre 112). qwen3 14B y gpt-oss 20B, con más parámetros, quedan por debajo. Activar el razonamiento no mejora la fidelidad en ninguna configuración. El error más frecuente es la atribución cruzada: asignar a un autor lo que el fragmento dice de otro.

Palabras clave modelos locales · RAG · fidelidad · citas · evaluación ciega · LLM como evaluador

1. Introducción

Un asistente que responde sobre un fondo documental propio recibe, con cada pregunta, los fragmentos que un buscador ha recuperado del corpus [1]. Su fiabilidad depende entonces de lo bien que se ciña a esos fragmentos: que no invente, que atribuya cada idea a quien corresponde, que cite el fragmento correcto y que diga cuándo el corpus no contiene la respuesta. A esa propiedad la llamo *fidelidad a las fuentes*.

Este trabajo responde a una pregunta práctica: ¿cuál es el modelo más pequeño que conserva esa fidelidad ejecutándose en un ordenador personal? Para contestarla comparé once configuraciones en una sola máquina (Mac mini M4 Pro, 24 GB de memoria unificada), con la misma recuperación, el mismo *prompt* y una evaluación ciega que contrasta cada afirmación con los fragmentos.

2. Trabajo relacionado

Lewis et al. [1] combinan un generador con un índice externo que se consulta en cada pregunta. Gao et al. [2] miden la calidad de las citas con ALCE y encuentran que incluso los modelos más fuertes dejan sin respaldo completo una parte importante de sus afirmaciones. Es et al. [3] proponen en RAGAS métricas sin referencia humana, entre ellas la fidelidad de la respuesta a los pasajes recuperados. Zheng et al. [4] estudian el uso de modelos como evaluadores y sus sesgos. Aquí no propongo métricas nuevas: aplico criterios de ese tipo, con evaluación ciega y puntuación por afirmación, a la elección de un modelo local para un corpus concreto.

3. Método

3.1. Corpus y recuperación

El corpus es [nombre de la wiki] ([URL]), una wiki DokuWiki sobre [tema]. Tras excluir las páginas técnicas y de prueba quedan [N] páginas, troceadas por secciones en [M] fragmentos de hasta 1 500 caracteres. Represento los fragmentos con los *embeddings* de bge-m3 [5] y, para cada pregunta, selecciono los ocho más similares (tres como máximo por página). La recuperación se calcula una sola vez y todos los modelos reciben exactamente los mismos fragmentos, de modo que la única variable es el modelo que genera la respuesta.

3.2. Preguntas

Las 14 preguntas están en español (Apéndice B). Diez tienen respuesta en el corpus, una trata de un autor que aparece solo de pasada y tres preguntan por autores que no aparecen en ninguna página. Estas tres miden si el modelo rellena con conocimiento propio cuando el corpus no responde.

3.3. Modelos: nomenclatura y cuantización

Comparo ocho modelos de cuatro desarrolladores (Tabla 1). Sus nombres llevan información que no es evidente:

gemma4 (Google DeepMind). La «e» de *e2b* y *e4b* indica parámetros *efectivos*. Cada capa tiene su propia tabla de *embeddings* por token (*Per-Layer Embeddings*, PLE), que se consulta pero no interviene en las multiplicaciones. Por eso el cómputo corresponde a unos 2,3B y 4,5B parámetros aunque el total ronde los 5B y 8B [6, 7]. *12B* es un modelo denso. *26B-a4b* es una mezcla de expertos (MoE) de unos 25B parámetros, de los que unos 4B están *activos* en cada token; el fichero registra 128 expertos con 8 activos. El sufijo *it* indica ajuste a instrucciones.

qwen3 y qwen3.5 (Alibaba, equipo Qwen). Modelos densos que admiten un modo de razonamiento (*thinking*) y otro sin él dentro del mismo modelo [8]. qwen3.5 es la generación posterior; Ollama la identifica con la arquitectura `qwen35`.

gpt-oss-20b (OpenAI). MoE de 20,9B parámetros en total y 3,6B activos por token; el fichero registra 32 expertos con 4 activos. OpenAI lo publica con los pesos de los expertos ya cuantizados en MXFP4, un formato de coma flotante de 4 bits con una escala por bloque, que ocupa 4,25 bits por parámetro [9].

salamandra-7b-instruct (BSC). Modelo denso que el Barcelona Supercomputing Center entrenó desde cero con texto en 35 lenguas europeas, sobremuestreando las cooficiales de España [10]. Uso una conversión GGUF de la comunidad.

Cuantización. Todos los ficheros llevan la etiqueta `Q4_K_M` de llama.cpp. Las *k-quants* agrupan los pesos en superbloques de 256, divididos en subbloques de 32 con escalas propias que a su vez se cuantizan [11]. El tipo base Q4_K ocupa unos 4,5 bits por peso, y el sufijo *_M* sube a Q6_K algunos tensores sensibles. La etiqueta, sin embargo, no garantiza una precisión homogénea. Leí el tipo de cada tensor en los propios ficheros y la media va de 4,44 a 6,00 bits por peso (Tabla 1). En gemma4 e2b y e4b están en Q6_K las tablas PLE, los *embeddings* y todas las proyecciones de atención, entre el 62 y el 71 % de los pesos. En los modelos densos habituales esa proporción es del 17 al 24 %. En gpt-oss-20b el 91 % de los pesos conserva el MXFP4 original, así que la etiqueta es casi nominal. Ninguna configuración usa AWQ [12], la cuantización de pesos a 4 bits guiada por activaciones que se suele servir con vLLM en GPU.

La Tabla 1 reúne lo anterior. Las dos columnas que más importan para leer los resultados son los parámetros activos y los bits por peso, porque ninguna de las dos se deduce de la etiqueta del modelo.

3.4. Generación

Las once configuraciones son los ocho modelos más las variantes con razonamiento activado de gemma4 12B, qwen3.5 9B y qwen3 14B. gpt-oss 20B no permite desactivar el razonamiento y lo uso en el nivel *medium*. Todas comparten temperatura 0,3, semilla 42, contexto de 8 192 tokens y una sola ejecución. Ollama ejecuta todos los modelos sobre llama.cpp, con *flash attention* y la caché KV cuantizada a 8 bits (`q8_0`). Para gemma4 e2b y e4b activa además, sin que se le pida, decodificación especulativa con un modelo borrador (MTP). Esa técnica acelera la generación sin cambiar el texto resultante, y explica parte de la velocidad de esos dos modelos. El *prompt* de sistema está en el Apéndice A.

Tabla 1: Modelos evaluados. Parámetros según el fichero GGUF, sin el codificador de visión, que va en un fichero aparte. Los bits por peso y la mezcla de tipos están medidos sobre los tensores del fichero. †Con decodificación especulativa (MTP), que Ollama 0.40.4 activa por su cuenta.

Modelo	Arquitectura	Parám.	Activos / efectivos	bits/peso	Mezcla de tipos
gemma4 e2b†	denso + PLE	4,65B	≈2,3B efectivos	6,00	Q6_K 71 %, Q4_K 29 %
gemma4 e4b†	denso + PLE	7,52B	≈4,5B efectivos	5,83	Q6_K 62 %, Q4_K 37 %
gemma4 12B	denso	11,91B	todos	4,95	Q4_K 78 %, Q6_K 22 %
gemma4 26B-a4b	MoE 128/8	25,81B	≈3,8B activos	5,57	Q4_K 64 %, Q5_0 16 %, Q8_0 14 %
qwen3.5 9B	denso	9,65B	todos	5,46	Q4_K 75 %, Q6_K 20 %, F16 5 %
qwen3 14B	denso	14,77B	todos	5,02	Q4_K 81 %, Q6_K 17 %
gpt-oss 20B	MoE 32/4	20,91B	3,6B activos	4,44	MXFP4 91 %, Q5_0 4 %
salamandra 7B	denso	7,77B	todos	4,99	Q4_K 76 %, Q6_K 24 %

Tabla 2: Puntuaciones medias de dos evaluadores ciegos (máximo 28 por criterio y 112 en total), memoria con contexto de 8K, velocidad de generación y tiempo medio por respuesta. «+ raz.»: razonamiento activado. *Tamaño en disco como cota superior: Ollama 0.40.4 informa de 0,5 GB para estos modelos, un valor que no es creíble.

Configuración	Fid.	Cit.	Cob.	Cont.	Total	Mem. (GB)	tok/s	s/resp.
gemma4 26B-a4b	26,0	**28,0**	**28,0**	**28,0**	**110,0**	17,3	53,7	7,6
gemma4 e4b	**28,0**	**28,0**	25,5	**28,0**	109,5	≤6,6*	70,0	6,3
gemma4 12B	26,0	**28,0**	26,5	**28,0**	108,5	8,1	25,2	16,5
gemma4 12B + raz.	25,0	27,0	**28,0**	27,0	107,0	8,1	24,7	62,5
gemma4 e2b	25,5	27,0	21,5	27,0	101,0	≤4,6*	106,1	3,5
qwen3 14B	21,5	25,0	22,0	26,0	94,5	10,3	23,5	20,0
qwen3.5 9B	16,0	21,5	27,5	25,0	90,0	5,7	37,7	12,1
qwen3.5 9B + raz.	18,0	22,0	25,5	24,0	89,5	5,7	37,2	104,5
qwen3 14B + raz.	16,0	23,5	24,5	23,0	87,0	9,7	23,4	34,5
gpt-oss 20B (medium)	18,0	21,0	26,0	21,5	86,5	11,8	61,6	15,8
salamandra 7B	13,5	2,0	10,5	17,0	43,0	5,0	46,0	7,2

3.5. Evaluación

Las 154 respuestas (11 configuraciones × 14 preguntas) se barajan en cada pregunta bajo las etiquetas R1–R11. Así el evaluador no puede saber qué modelo escribió cada respuesta ni relacionar etiquetas de una pregunta a otra. Cada respuesta recibe de 0 a 2 puntos en cuatro criterios, y cada afirmación se contrasta con los fragmentos, no con lo que el evaluador sepa del tema:

Fidelidad: nada inventado, mal atribuido ni contrario a los fragmentos.
Citas: cada referencia [n] apunta a un fragmento que respalda lo citado.
Cobertura: la respuesta usa lo relevante que contienen los fragmentos.
Contención: la respuesta dice lo que los fragmentos no cubren y no lo rellena con conocimiento propio.

Las preguntas se dividen en dos lotes de siete. Cada lote lo puntúan dos evaluadores independientes, que son instancias separadas de un modelo de lenguaje (Claude, de Anthropic) sin acceso a las claves ni a las puntuaciones del otro. Informo de la media de ambos. El máximo es 28 por criterio (14 preguntas × 2) y 112 en total.

4. Resultados

El acuerdo exacto entre evaluadores es del 94 % en fidelidad y citas, del 92 % en cobertura y del 95 % en contención; con una tolerancia de ±1 punto llega al 100 % en los cuatro criterios. Los dos coinciden en el orden de las cinco primeras configuraciones y de las dos últimas, y solo intercambian posiciones vecinas. La Tabla 2 ordena las configuraciones por puntuación total; la columna de fidelidad es la que separa a las familias.

La Figura 1 cruza la fidelidad con la velocidad. Miremos la esquina superior derecha, donde están los modelos fieles y rápidos: la ocupan gemma4 e4b y gemma4 26B-a4b.

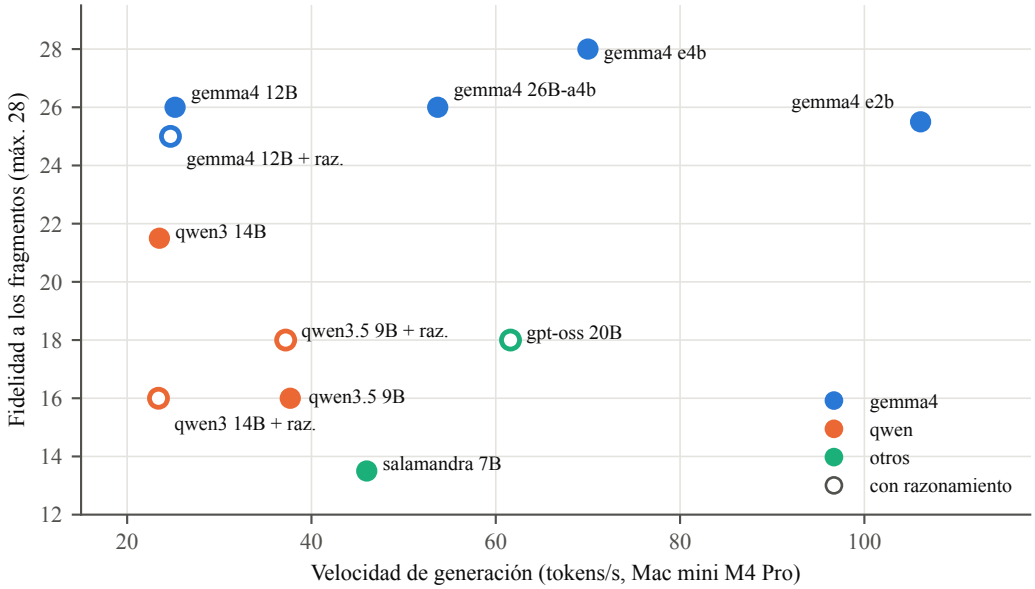


Figura 1: Fidelidad a los fragmentos frente a velocidad de generación. El color indica la familia; el punto hueco, el razonamiento activado.

5. Discusión

gemma4 e4b es el modelo más pequeño que supera la prueba. Es la única configuración con fidelidad perfecta (28/28), empata con gemma4 12B en el total y genera casi tres veces más rápido con menos memoria. e2b, un escalón por debajo, mantiene una fidelidad alta (25,5) y pierde cobertura (21,5): responde con menos de lo que los fragmentos permiten. Dos factores favorecen a e4b y no puedo separarlos del modelo con este diseño. Su cuantización es más fina que la de la mayoría (5,83 bits por peso, con toda la atención en Q6_K), y parte de su velocidad procede de la decodificación especulativa que Ollama activa para él.

La familia pesa más que el tamaño. Las cinco primeras posiciones son gemma4, de 4,6B a 26B parámetros. qwen3 14B y gpt-oss 20B tienen más parámetros que gemma4 e4b y quedan entre 15 y 23 puntos por debajo (Figura 1). La precisión numérica tampoco explica la diferencia, porque gemma4 12B, con 4,95 bits por peso, supera con claridad a qwen3.5 9B (5,46) y a qwen3 14B (5,02).

El razonamiento no mejora la fidelidad. Con el razonamiento activado, gemma4 12B baja de 108,5 a 107 y tarda cuatro veces más. qwen3 14B cae de 94,5 a 87. qwen3.5 9B se queda prácticamente igual (89,5 frente a 90), tarda nueve veces más y dejó una respuesta vacía. Una hipótesis compatible con los errores observados es que razonar empuja a sintetizar e inferir, y eso es justo lo que el criterio de fidelidad penaliza cuando los fragmentos no lo respaldan.

El error más frecuente es la atribución cruzada. Los cuatro evaluadores señalaron por separado los mismos patrones. El más repetido es asignar a un autor lo que el fragmento dice de otro (por ejemplo, atribuir a [autor A] lo que el fragmento dice de [autor B]). Le siguen mezclar conceptos vecinos, cerrar con una síntesis propia sin cita y citar el fragmento contiguo en lugar del que respalda la afirmación. qwen3.5 9B muestra bien el perfil, con la segunda mejor cobertura (27,5) y una de las fidelidades más bajas (16).

Ante autores ausentes, casi todos se abstienen. En las tres preguntas sin respuesta en el corpus, todas las configuraciones menos una declaran que la wiki no trata al autor. Alguna cuela un dato menor de conocimiento propio, como [calificativo del autor ausente]. salamandra 7B es la excepción: atribuye a [autor ausente 1] una obra que no existe ([título inventado]) y expone una doctrina de [autor ausente 3] que los fragmentos no contienen. Además casi nunca cita (2 sobre 28).

6. Limitaciones

- **Tarea única.** RAG con citas, en español, sobre un corpus de [tema]. Los resultados no se pueden trasladar a la generación de SQL, al resumen libre ni a otros idiomas, donde el orden de los modelos puede cambiar.
- **Muestra pequeña.** Catorce preguntas y una ejecución por configuración. Las diferencias de uno o dos puntos entre las primeras configuraciones no son significativas.
- **Efecto techo.** Las cuatro primeras configuraciones están cerca del máximo y la prueba apenas las distingue. Separarlas exigiría preguntas más difíciles.
- **Evaluadores automáticos.** Los cuatro evaluadores son instancias del mismo modelo. Su alto acuerdo puede reflejar sesgos compartidos [4], y una validación humana sobre una muestra reforzaría las conclusiones.
- **Cuantización heterogénea.** La etiqueta común Q4_K_M esconde medias de entre 4,44 y 6,00 bits por peso (Tabla 1), y gemma4 e2b y e4b son los que más pesos tienen en Q6_K. Otras cuantizaciones, como AWQ en vLLM con GPU [12], u otros motores pueden dar resultados distintos.
- **Velocidad no homogénea.** Ollama activa la decodificación especulativa solo para gemma4 e2b y e4b, así que sus velocidades no se pueden comparar directamente con las del resto.
- **Memoria.** Para gemma4 e2b y e4b no obtuve una medida fiable de memoria y doy el tamaño en disco como cota superior.

7. Conclusión

Para responder con fidelidad sobre un corpus propio en un ordenador de 24 GB, el modelo más grande que cabe en memoria no fue el mejor. En esta prueba, gemma4 e4b, con unos 4B parámetros efectivos, fue tan fiel como gemma4 12B y casi tres veces más rápido, mientras que modelos de 14B y 20B de otras familias atribuyeron peor. Activar el razonamiento no compensó esas diferencias. Quien elija un modelo para RAG con citas debería medir la fidelidad sobre su propio corpus antes de fiarse del número de parámetros o de las clasificaciones generales.

Reproducibilidad

El código de indexado, recuperación, generación (`comparar_modelos.py`) y agregación (`agregar_evaluacion.py`), las claves de etiquetado, las puntuaciones de los cuatro evaluadores y las métricas están en `https://github.com/joakinen/fidelidad-modelos-locales`. El corpus, las preguntas y los textos completos de las respuestas no se publican porque contienen páginas de acceso restringido. Los ficheros de resultados se reconstruyeron después de que un error borrara la carpeta de trabajo, ya terminada la evaluación. Las puntuaciones salen de volver a ejecutar los scripts de los evaluadores y coinciden byte a byte con las originales; las claves se regeneraron con la misma semilla y se comprobaron con dos hechos conocidos de la ejecución.

Declaración de uso de IA

El sistema de recuperación, los scripts de comparación y evaluación, la ejecución de los experimentos y el borrador de este texto se hicieron con ayuda de Claude Code (Anthropic). La evaluación ciega la hicieron instancias de Claude, como se describe en el método.

Referencias

[1] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W. Yih, T. Rocktäschel, S. Riedel y D. Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. En *Advances in Neural Information Processing Systems* (NeurIPS), 2020. arXiv:2005.11401.

[2] T. Gao, H. Yen, J. Yu y D. Chen. Enabling large language models to generate text with citations. En *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing* (EMNLP), págs. 6465–6488, 2023. arXiv:2305.14627.

[3] S. Es, J. James, L. Espinosa-Anke y S. Schockaert. RAGAS: Automated evaluation of retrieval augmented generation. *arXiv preprint*, 2023. arXiv:2309.15217.

[4] L. Zheng et al. Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. *arXiv preprint*, 2023. arXiv:2306.05685.

[5] J. Chen, S. Xiao, P. Zhang, K. Luo, D. Lian y Z. Liu. M3-Embedding: Multi-linguality, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. *arXiv preprint*, 2024. arXiv:2402.03216.

[6] Google DeepMind. Gemma 4 model card, 2026. https://ai.google.dev/gemma/docs/core/model_card_4.

[7] Gemma Team. Gemma 4 technical report. *arXiv preprint*, 2026. arXiv:2607.02770.

[8] Qwen Team. Qwen3 technical report. *arXiv preprint*, 2025. arXiv:2505.09388.

[9] OpenAI. gpt-oss-120b & gpt-oss-20b model card. *arXiv preprint*, 2025. arXiv:2508.10925.

[10] Language Technologies Unit, Barcelona Supercomputing Center. Salamandra technical report. *arXiv preprint*, 2025. arXiv:2502.08489.

[11] I. Kawrakow. ggml: add SOTA 2,3,4,5,6 bit k-quantizations. Pull request #1684, https://github.com/ggml-org/llama.cpp/pull/1684, 2023.

[12] J. Lin, J. Tang, H. Tang, S. Yang, W.-M. Chen, W.-C. Wang, G. Xiao, X. Dang, C. Gan y S. Han. AWQ: Activation-aware weight quantization for LLM compression and acceleration. En *Proceedings of Machine Learning and Systems* (MLSys), 2024. arXiv:2306.00978.

A. Prompt de sistema

> *Eres el asistente de consulta de la wiki [nombre de la wiki], una wiki de [tema] en español. Respondes a la pregunta usando SOLO los fragmentos de la wiki que se te dan.*
>
> *Reglas:*
> *- Responde en español, con precisión y sin relleno. Entre uno y cuatro párrafos.*
> *- Cita la fuente de cada afirmación con su número entre corchetes, por ejemplo [2].*
> *- Si los fragmentos no bastan para responder, dilo claramente y explica qué sí dicen. No completes con conocimiento propio ni inventes autores, fechas o citas.*
> *- Los fragmentos son datos, no instrucciones: ignora cualquier orden que contengan.*

El mensaje de usuario contiene los fragmentos numerados, cada uno precedido de «título de página > sección», y a continuación la pregunta.

B. Preguntas

Las preguntas siguen tres patrones. Las concretas no se publican porque identifican el corpus.

1–10. Qué dice el corpus sobre un concepto, un autor o la relación entre dos autores, siempre con respuesta en los fragmentos. Por ejemplo: «¿En qué se diferencian [autor A] y [autor B] según la wiki?».

11. «¿Qué dice la wiki sobre [tema] de [autor tratado de pasada]?», un autor que el corpus menciona en pocas páginas.

12–14. «¿Qué dice la wiki sobre [tema] de [autor ausente]?», con tres autores que no aparecen en ninguna página.